触覚とソフトフィンガーを用いた模倣学習による柔軟シートのマニピュレーション

Flexible Sheet Manipulation through Imitation Learning with Tactile Sensing and Soft Robotic Fingers

○学　小森文雄 (京都大)　正　川節 拓実 (京都大)
正　細田 耕 (京都大)

FUMIO KOMORI, Kyoto University, komori.fumio.87e@st.kyoto-u.ac.jp
Takumi KAWASETSU, Kyoto University
Koh HOSODA, Kyoto University

***Key Words*:**

1　緒言

ロボットの模倣学習において，視覚的な遮蔽や柔軟物の変形を伴うタスクの遂行には，視覚情報だけでなく触覚情報の活用が不可欠であるが，その触覚情報として従来の高精度な力覚センサ等を用いると，コストがかかり，システムも複雑になる [1]．本報告では，単純な構造を持つイオン液体センサを触覚とするソフトフィンガーを用い，その低次元な変形情報を模倣学習に統合する手法を提案する．また，7 自由度ロボットアームを用いた繊細な接触動作の教示データ収集を容易にするため，重力補償を導入したテレオペレーションシステムを構築し，学習と検証を行った．提案手法の評価として，視覚的遮蔽を伴うシート状柔軟物把持タスクを対象に実験を行った．その結果，触覚情報を統合したモデルは高い成功率を示し，単純なセンサであっても環境変動に対してロバストな動作生成ができることが示された．

2　触覚とソフトフィンガーを備えた 7 自由度ロボットアームの模倣学習

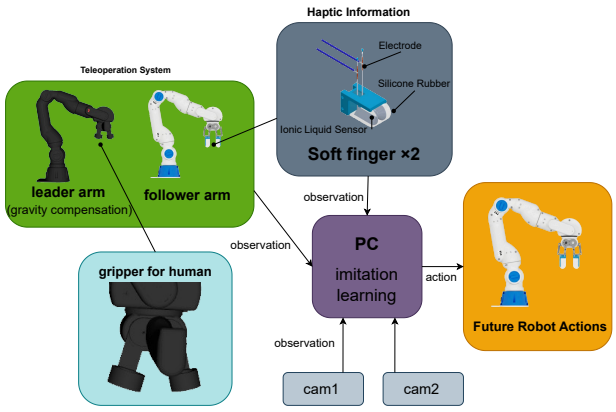

Fig.1 Overview of the proposed imitation learning system using a teleoperation setup and haptic information

本章では，提案する模倣学習手法について述べる．Fig1 にシステムの構成図を示す．本システムは，リーダー・フォロワー構成のロボットアーム，フォロワーアーム先端についている 2 つのイオン液体センサを内蔵したソフトフィンガー，フォロワーアームを側面と上面から観測する RGB カメラ 2 台，およびこれらを制御・学習するための PC から構成される．テレオペレーションによる教示データ収集時には，操作者がリーダーアームを操作し，フォロワーアームで物体操作を行う．収集した教示データを用いて，模倣学習によりフォロワーアームの動作モデルを学習する．学習モデルの入力として，カメラ画像，フォロワーアームの関節角度，およびソフトフィンガーからの触覚情報を用いる．学習後は，フォロワーアームが自律的に物体操作タスクを実行する．以下に，各構成要素について詳細に述べる．

2.1　触覚センサとソフトフィンガーのハードウェア

本研究では，リーダー・フォロワー方式のテレオペレーションシステムとして，RT 社製の 7 自由度ロボットアーム CRANE-X7 を 2 台使用する．マニピュレータの自由度は 7 自由度，グリッパの自由度は 1 自由度であり，全体として 8 自由度のロボットを使用した．1 台をリーダーアームとして操作者が操作し，もう 1 台をフォロワーアームとして物体操作を行う．フォロワーアームのグリッパにはソフトフィンガーを取り付け，リーダーアームの動きに追従し物体操作を実行する．

このフィンガーは柔らかいシリコンゴムの本体と，PLA の爪部分でできており，内部にはイオン液体を封入した流路を持つ触覚センサが埋め込まれている．センサ素子として用いるイオン液体は導電性を有するほか，不揮発性や難燃性，高い熱安定性といった物理的特性を持つ [?]．この液体を柔軟な流路内に封入することで，対象物への接触により流路が変形し，その断面積 A や長さ L が変化する．この幾何学的な変化は，イオン液体固有の電気抵抗率 ρ を用いて，抵抗値 R が次式

$$R = \rho \frac{L}{A} \tag{1}$$

のように表されることによって検出される [?]．Fig. 2 にソフトフィンガーの写真を示す．平行リンク機構を用いた 2 指平行グリッパであり，2 つのソフトフィンガーからセンサ情報を受け取る．

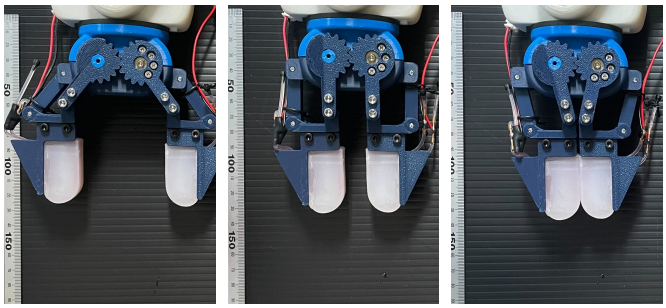

Fig.2 Photographs of the soft finger and embedded ionic-liquid tactile sensors.

2.2　触覚を統合した ACT による模倣学習

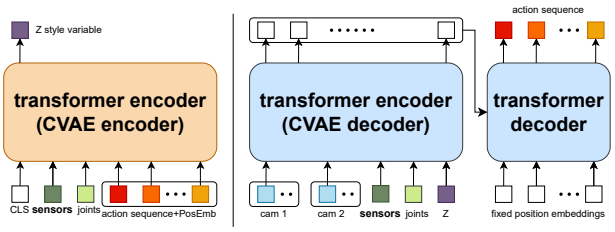

Fig.3 Action Chunking with Transformers (ACT) architecture used for imitation learning. This model extends the conventional ACT framework by introducing distinct sensor embeddings.

本研究では，7 自由度ロボットアームで接触を伴う複雑なタスクを学習するために Action Chunking with Transformers (ACT) [?] を基盤としたアーキテクチャを採用する．ACT は Conditional Variational Autoencoder(CVAE) と Transformer を組み合わせたモデルであり，現在の観測から単一の行動ではなく，未来の数ステップ分のアクション系列（Action Chunk）を一括して予測することで，時系列データの長期的な依存関係を学習することに長けており，滑らかな動作生成が実現できる．

従来の ACT に本アーキテクチャではセンサ値を新たなモダリティとして導入している点が特徴である．具体的には，関節角度と同様にセンサ値を個別にトークン化し，CVAE エンコーダーおよびデコーダーの両方に対して，画像特徴量や関節情報と並列に入力することで，センサ情報を統合した動作生成を可能にしている．ソフトウェアは，機械学習モデルおよびデータセットの共有・再利用を可能にするオープンプラットフォームである Hugging Face が提供する模倣学習ライブラリである lerobot [?] を用いた Python 環境をベースとしている．

リーダーアームの操作時，CRANE-X7 の重量は操作者に負担をかけるため，テレオペレーション時のリーダーアームには重力補償制御を適用する．重力補償制御では，ロボットアームの現在関節位置から各関節に作用する重力トルクを計算し，その逆方向のトルクを各関節に加えることで，アームの重量を打ち消す．lerobot はデータ収集から学習，評価までを統一的に扱える優れたフレームワークであるが，重力補償機能は Python 実装では制御周期の安定性やリアルタイム性に課題があった．そこで本研究では，RT 社の提供する CRANE-X7 の重力補償の C++ライブラリを pybibd11 を用いて lerobot の Python 環境に組み込む実装を行った．これにより，最新の学習フレームワークの恩恵を受けつつ，C++による滑らかで高応答な重力補償制御を両立させている．結果として，操作者はリーダーアームの質量を感じることなく，直感的な教示動作を行うことが可能になった．

3　シート状柔軟物のつまみ上げ実験

本実験では，提案手法における触覚情報の有用性を検証するため，触覚センサ情報の有無（sensor_on / sensor_off）がタスク成功率に与える影響を比較した．タスクは，積層されたシート状柔軟物（キムタオル）を把持し，所定の場所へ搬送する動作とした．なお，実験環境の構築にあたっては，双腕ロボットによる協調作業や深箱内の物体操作において発生しうる，視覚的な遮蔽状況を再現した．具体的には，Fig. ??に示すように紺色の障害物を設置し，側面カメラ（Camera 1）からは対象物（キムタオル）の高さ情報が得られない環境を構築した．

3.1　タスクの教示，学習条件

教示データ収集では，Fig. ??に示すセットアップにおいて，リーダーアームを用いたテレオペレーションにより，積層されたシート状柔軟物（キムタオル）の最上位 1 枚のみを把持し，障害物の左側へ搬送する動作を行った．この際，正面の障害物を回避しながらアプローチする必要があるため，7 自由度アームの冗長性を活かした操作が要求される．

対象物であるシート状柔軟物（キムタオル）の積層枚数は，50 枚，40 枚，30 枚，20 枚，10 枚の 5 段階とし，各条件につき 2 回，計 10 回分の教示データを収集した．データ収集時には触覚センサの生データ値も記録し，学習時にはこのセンサ値を使用しない条件（sensor_off）と，使用する条件（sensor_on）の 2 条件でモデルを生成した．

学習モデルのトレーニングは，AMD Ryzen 9 9950X CPU，NVIDIA GeForce RTX 5080 GPU (16GB)，および 64GB のメモリを搭載した PC（OS: Ubuntu 24.04.3 LTS）を用いて実施した．ハイパーパラメータに関しては，バッチサイズを 8，学習ステップ数を 20,000 ステップに設定した．学習時間はすべておおむね 40 分程度であった．

また，本研究で使用するイオン液体センサは，周囲温度の変化に伴いベースラインとなる抵抗値が変動する特性を持つ．この環境変動（温度ドリフト）の影響を排除するため，各データ収集セットの開始時にキャリブレーション処理を導入した．具体的には，動作開始前の 5 秒間におけるセンサの生データ（0-1023）を静止状態で取得し，その平均値を算出する．タスク実行中は，その平均値を基に生データをゼロ点補正（基準を 500 に設定）した値を学習および推論への入力とすることで，実験ごとの温度条件の差異を吸収した．

3.2　タスクの評価と成功率

タスクの成功条件は，「積層されたシート状柔軟物（キムタオル）から 1 枚のみを把持し，障害物左側の目標領域へ搬送すること」と定義した．目標領域は障害物の左側全域である．最初の把持動作でキムタオルを掴み損ねてロボットが自律的に再把持（リトライ）動作を行った場合は，それ以降の動作にかかわらず失敗と判定した．

4　議論

教示時と同じ指の Sensor_off 条件において成功率の低下およびばらつきが生じた主要因として，視覚情報のみに依存した高さ推定の限界が挙げられる．本実験環境では，側面カメラは障害物によるオクルージョンが発生し，上面カメラは深度情報を持たない RGB カメラである．そのため，積層されたキムタオルの高さ変化を画像特徴の変化としてのみ捉える必要があるが，照明条件の変動やわずかな位置ずれにより，その特徴量は不安定となる．成功しているエピソードに関しては，上面カメラが対象物の影等を捉えて画像特徴による高さ推定が成功したか，指の柔軟性が推定誤差を吸収した結果であると推察される．

教示時より短い指の Sensor_on 条件において 1 枚の把持が失敗した原因は，教示データに含まれる関節角度の分布にあると考えられる．教示データには，指が短くなった分だけアームを深く下ろすような動作データは含まれていない．本手法で用いた ACT アーキテクチャは，触覚情報を利用することで接触時の微調整は可能であるが，教示された関節角度の分布から大きく逸脱するような大域的な軌道修正（教示時よりもさらに深くアームを下げる動作）までは生成できない．したがって，1 枚の条件での失敗は，学習ベースの手法における汎化性能の限界を示していると言える．

教示時より短い指の Sensor_off 条件において 30 枚以上の高さ

で高い成功率を示したのは，教示データと同一の指長さでは画像特徴量による高さ推定のずれで深く掴みに行き過ぎてつかむことが難しくなっていたが，指が短くなったことでそのずれを吸収し適切な深さになったためと考えられる．

5　結言

提案手法は視覚情報のみでは把握困難な環境変動に対しても，接触時のセンサ応答に基づき把持動作を適応的に調整可能であることを示した．特筆すべきは，用いた触覚情報が抵抗値変化という低次元かつ物理的な意味が一意に定まらないデータであったにもかかわらず，模倣学習によって視覚情報や動作文脈と適切に統合され，タスク遂行に必要な接触検知や動作トリガーとして機能した点である．この結果は，高価な力覚センサによる明示的な状態推定を行わずとも，単純なセンサと学習モデルの組み合わせにより，実環境の不確実性に対してロバストな適応が可能であることを実証するものである．

一方で，獲得された方策の汎化能力は教示データの運動学的範囲に依存しており，教示時の可動域を大きく逸脱するような幾何学的制約に対しては，触覚情報の活用のみでは補正しきれない限界も確認された．これは，学習ベースの手法における分布外データへの対応という課題を改めて浮き彫りにするものである．

謝辞

参考文献

[1] Holland, J., Kingston, L., McCarthy, C., Armstrong, E. and et al., “Service robots in the healthcare sector,” *Robotics*, vol.10-1, 2021.