触覚とソフトフィンガーを用いた模倣学習による柔軟シートのマニピュレーション

Flexible Sheet Manipulation through Imitation Learning with Tactile Sensing and Soft Robotic Fingers

○ 小森文雄 (京都大) 辻 大樹 (京都大)
川節 拓実 (京都大) 細田 耕 (京都大)

FUMIO KOMORI, Kyoto University, komori.fumio.87e@st.kyoto-u.ac.jp
Hiroki TSUJI, Kyoto University
Takumi KAWASETSU, Kyoto University
Koh HOSODA, Kyoto University

This paper presents a method for integrating tactile information from soft robotic fingers into imitation learning for robotic manipulation tasks. The proposed system utilizes simple ion liquid sensors embedded in soft fingers to capture tactile feedback, which is then directly fed into a learning model based on Action Chunking with Transformers (ACT). The method is evaluated on a sheet-like flexible object grasping task that involves visual occlusion, demonstrating that the integration of tactile information enables robust performance even with simple sensors. The results suggest that the combination of soft robotic fingers and learning-based approaches can effectively handle complex contact transitions and environmental variations in manipulation tasks.

Key Words: imitation learning, tactile sensing, soft robotic fingers,flexible object manipulation

1 緒言

ロボットマニピュレーションにおいて，模倣学習の発展により視覚情報を中心とした複雑なタスクが実現されつつある [1]．しかし，視覚的な遮蔽や柔軟物の変形を伴うタスクの遂行には，視覚情報だけでなく触覚情報の活用が不可欠である．特に，紙や布などに代表されるシート状柔軟物のマニピュレーションにおいては，指先の接触によって局所的な形状変化を起こし，掴みしろを生成する過程が必要となる．この過程では接触状態が連続的に推移し，指先による視覚的遮蔽も生じやすいため，視覚のみによる状態推定は不安定になる [2,3]．この課題に対し，従来は高精度な力覚・触覚センサを用いた接触状態の明示的な推定が行われてきた [4]．しかし，これらの手法はシステムの複雑化や高コスト化が問題となる．

本報告では，この課題を解決するため，単純な構造のセンサを触覚とするソフトフィンガーを用い，その触覚情報を模倣学習に統合する手法を提案する．接触状態を精密に推定する代わりに，人間の指先のように受動変形によって環境のばらつきを吸収できるソフトフィンガーと，その内部に実装した単純な構造のイオン液体センサを用いる．このセンサから得られる低次元な触覚情報を，そのまま模倣学習モデルに入力し，学習と検証を行う．提案手法の評価として，視覚的遮蔽を伴うシート状柔軟物把持タスクを対象に実験を行った．その結果，触覚情報を統合したモデルは高い成功率を示し，単純なセンサであっても掴みしろ生成を含む複雑な接触遷移において，環境変動に対してロバストな動作生成が可能であることが示された．

2 触覚とソフトフィンガーを備えた 7 自由度ロボットアームの模倣学習

本システムは，リーダー・フォロワー構成のロボットアーム，フォロワーアーム先端についている 2 つのイオン液体センサを内蔵したソフトフィンガー，フォロワーアームを側面と上面から観測する RGB カメラ 2 台，およびこれらを制御・学習するための PC から構成される．テレオペレーションによる教示データ収集時には，操作者がリーダーアームを操作し，フォロワーアームで物体操作を行う．収集した教示データを用いて，模倣学習によりフォロワーアームの動作モデルを学習する．学習モデルの入力として，カメラ画像，フォロワーアームの関節角度，およびソフトフィンガーからの触覚情報を用いる．学習後は，フォロワーアームが自律的に物体操作タスクを実行する．以下に，各構成要素について詳細に述べる．

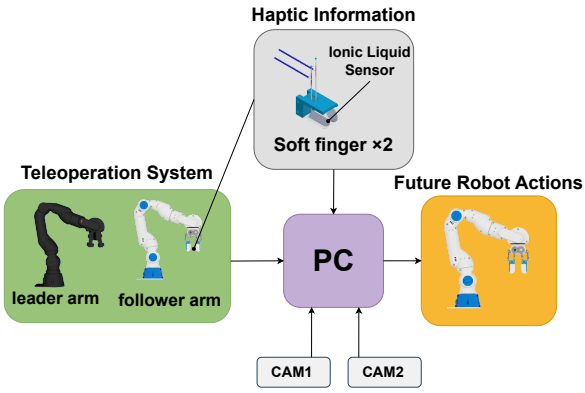

Fig.1 Overview of the proposed imitation learning system using a teleoperation setup and haptic information

2.1 触覚センサとソフトフィンガーのハードウェア

本研究では，リーダー・フォロワー方式のテレオペレーションシステムとして，RT 社製の 7 自由度ロボットアーム CRANE-X7 を 2 台使用する．マニピュレータの自由度は 7 自由度，グリッパの自由度は 1 自由度であり，全体として 8 自由度のロボットを使用した．1 台をリーダーアームとして操作者が操作し，もう 1 台をフォロワーアームとして物体操作を行う．フォロワーアームのグリッパにはソフトフィンガーを取り付け，リーダーアームの動きに追従し物体操作を実行する．

このフィンガーは柔らかいシリコンゴムの本体と，PLA の爪部分でできており，内部にはイオン液体を封入した流路を持つ触覚センサが埋め込まれている．センサ素子として用いるイオン

液体は導電性を有するほか，不揮発性や難燃性，高い熱安定性といった物理的特性を持つ [5]．この液体を柔軟な流路内に封入することで，対象物への接触により流路が変形し，その断面積 A や長さ L が変化する．この幾何学的な変化は，イオン液体固有の電気抵抗率 ρ を用いて，抵抗値 R が次式

$$R = \rho \frac{L}{A} \tag{1}$$

のように表されることによって検出される [6]．フォロワーアームに取り付けられているのは平行リンク機構を用いた 2 指平行グリッパであり，2 つのソフトフィンガーからセンサ情報を受け取る．

2.2　触覚を統合した ACT による模倣学習

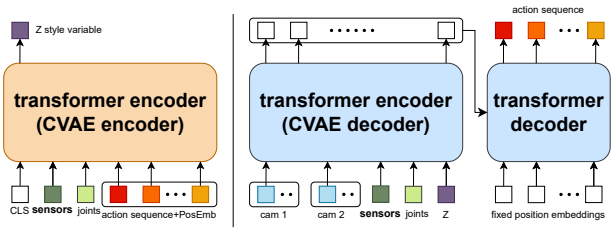

Fig.2 Action Chunking with Transformers (ACT) architecture used for imitation learning．This model extends the conventional ACT framework by introducing distinct sensor embeddings.

本研究では，7 自由度ロボットアームで接触を伴う複雑なタスクを学習するために Action Chunking with Transformers (ACT) [1] を基盤としたアーキテクチャを採用する．ACT は Conditional Variational Autoencoder(CVAE) と Transformer を組み合わせたモデルであり，現在の観測から単一の行動ではなく，未来の数ステップ分のアクション系列（Action Chunk）を一括して予測することで，時系列データの長期的な依存関係を学習することに長けており，滑らかな動作生成が実現できる．

従来の ACT に本アーキテクチャではセンサ値を新たなモダリティとして導入している点が特徴である．具体的には，関節角度と同様にセンサ値を個別にトークン化し，CVAE エンコーダーおよびデコーダーの両方に対して，画像特徴量や関節情報と並列に入力することで，センサ情報を統合した動作生成を可能にしている．ソフトウェアは，機械学習モデルおよびデータセットの共有・再利用を可能にするオープンプラットフォームである Hugging Face が提供する模倣学習ライブラリである lerobot [7] を用いた．

リーダーアームの操作時，CRANE-X7 の重量は操作者に負担をかけるため，テレオペレーション時のリーダーアームには重力補償制御を適用する．重力補償制御では，ロボットアームの現在関節位置から各関節に作用する重力トルクを計算し，その逆方向のトルクを各関節に加えることで，アームの重量を打ち消す．その結果，操作者はリーダーアームの質量を感じることなく，直感的な教示動作を行うことが可能になった．

3　シート状柔軟物のつまみ上げ実験

本実験では，提案手法における触覚情報の有用性を検証するため，触覚センサ情報の有無（sensor_on / sensor_off）がタスク成功率に与える影響を比較した．タスクは，積層されたシート状柔軟物（キムタオル）を把持し，所定の場所へ搬送する動作とした．なお，実験環境の構築にあたっては，双腕ロボットによる協調作業や深箱内の物体操作において発生しうる，視覚的な遮蔽状況を再現した．具体的には，Fig. 3 に示すように紺色の障害物を設置し，側面カメラ（Camera 1）からは対象物（キムタオル）の高さ情報が得られない環境を構築した．

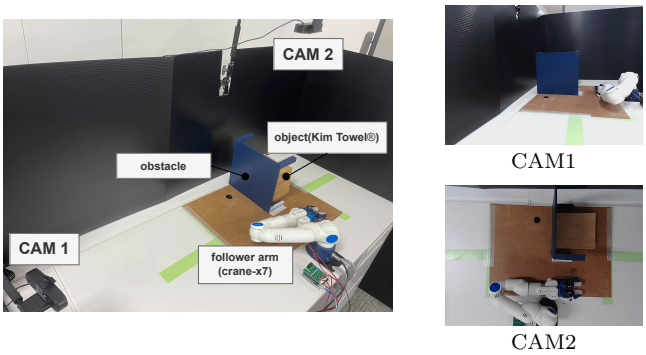

Fig.3 Experimental setup for the grasping task (left) and camera views (right)．Camera 1 provides a lateral view and Camera 2 provides a top view．An obstacle is placed so that the target Kim towel is occluded from the lateral view.

3.1　タスクの教示，学習条件

教示データ収集では，Fig. 3 に示すセットアップにおいて，リーダーアームを用いたテレオペレーションにより，積層されたシート状柔軟物（キムタオル）の最上位 1 枚のみを把持し，障害物の左側へ搬送する動作を行った．対象物であるシート状柔軟物（キムタオル）の積層枚数は，50 枚，40 枚，30 枚，20 枚，10 枚の 5 段階とし，各条件につき 2 回，計 10 回分の教示データを収集した．データ収集時には触覚センサの生データ値も記録し，学習時にはこのセンサ値を使用しない条件（sensor_off）と，使用する条件（sensor_on）の 2 条件でモデルを生成した．

学習モデルのトレーニングは，AMD Ryzen 9 9950X CPU，NVIDIA GeForce RTX 5080 GPU (16GB)，および 64GB のメモリを搭載した PC（OS: Ubuntu 24.04.3 LTS）を用いて実施した．ハイパーパラメータに関しては，バッチサイズを 8，学習ステップ数を 20,000 ステップに設定した．学習時間はすべておおむね 40 分程度であった．

また，本研究で使用するイオン液体センサは，周囲温度の変化に伴いベースラインとなる抵抗値が変動する特性を持つ．この環境変動（温度ドリフト）の影響を排除するため，各データ収集セットの開始時にキャリブレーション処理を導入した．具体的には，動作開始前の 5 秒間におけるセンサの生データ（0-1023）を静止状態で取得し，その平均値を算出する．タスク実行中は，その平均値を基に生データをゼロ点補正（基準を 500 に設定）した値を学習および推論への入力とすることで，実験ごとの温度条件の差異を吸収した．

3.2　タスクの評価と成功率

タスクの成功条件は，「積層されたシート状柔軟物（キムタオル）から 1 枚のみを把持し，障害物左側の目標領域へ搬送すること」と定義した．目標領域は障害物の左側全域である．最初の把持動作でキムタオルを掴み損ねてロボットが自律的に再把持（リトライ）動作を行った場合は，それ以降の動作にかかわらず失敗と判定した．以下の表に，各条件での成功率を示す．Table1 は指先を教示データと同じ長さにした場合，Table2 は指先を 30mm 短くした場合の成功率である．

教示データと同一の指長さを用いた場合，Sensor_on 条件では教示データに含まれない高さ条件であっても 100%の成功率を達

Table 1 Success rate with fingers extended by 30mm (same as training dataset)

sheets	sensor_on	sensor_off
60	100.0(5/5)	20.0(1/5)
50	100.0(5/5)	60.0(3/5)
40	100.0(5/5)	0.0(0/5)
30	100.0(5/5)	100.0(5/5)
20	100.0(5/5)	100.0(5/5)
10	100.0(5/5)	100.0(5/5)
1	100.0(5/5)	20.0(1/5)

Table 2 Success rate with fingers extended by 0mm (different from training dataset)

sheets	sensor_on	sensor_off
60	100.0(5/5)	100.0(5/5)
50	100.0(5/5)	80.0(4/5)
40	100.0(5/5)	100.0(5/5)
30	100.0(5/5)	100.0(5/5)
20	80.0(4/5)	0.0(0/5)
10	100.0(5/5)	0.0(0/5)
1	0.0(0/5)	0.0(0/5)

成した．一方で，Sensor_off 条件では，把持高さが教示データと異なる場合に成功率が著しく低下したほか，教示データと同一の高さであっても一部で成功率の低下が確認された．これは，ソフトフィンガーが対象に接触した際の抵抗値変化をトリガーとして把持動作が調整されているためであることが示唆される．すなわち，視覚情報の不確実性を触覚情報が補完することで，環境変動（高さの変化）に対するロバスト性が向上したと結論付けられる．Sensor_off 条件における失敗エピソードを確認すると，アームが対象の手前で停止する，あるいは押し込んではいるがつかみ損ねるといった動作が確認されたため，失敗は画像特徴量による高さ推定の精度不足に起因すると考えられる．次に，指の長さが教示時より短い場合，Sensor_on 条件は概ね高い成功率を維持した．しかし，対象物が「1 枚」の場合に限っては，把持に失敗し成功率は 0%となった．

4　結言

提案手法は視覚情報のみでは把握困難な環境変動に対しても，接触時のセンサ応答に基づき把持動作を適応的に調整可能であることを示した．特筆すべきは，用いた触覚情報が抵抗値変化という低次元かつ物理的な意味が一意に定まらないデータであったにもかかわらず，模倣学習によって視覚情報や動作文脈と適切に統合され，タスク遂行に必要な接触検知や動作トリガーとして機能した点である．この結果は，高価な力覚センサによる明示的な状態推定を行わずとも，単純なセンサと学習モデルの組み合わせにより，実環境の不確実性に対してロバストな適応が可能であることを実証するものである．

一方で，教示時より短い指の Sensor_on 条件において 1 枚の把持が失敗した原因は，教示データに含まれる関節角度の分布にあると考えられる．教示データには，指が短くなった分だけアームを深く下ろすような動作データは含まれていない．本手法で用いた ACT アーキテクチャは，触覚情報を利用することで接触時の微調整は可能であるが，教示された関節角度の分布から大きく逸脱するような大域的な軌道修正（教示時よりもさらに深くアームを下げる動作）までは生成できない．したがって，1 枚の条件での失敗は，学習ベースの手法における汎化性能の限界を示していると言える．

参考文献

[1] Zhao, T. Z., Kumar, V., Levine, S. and Finn, C., “Learning fine-grained bimanual manipulation with low-cost hardware,” arXiv:2304.13705, 2023.

[2] Zhu, Y., Yang, D. and Lee, Y., “Deformable and fragile object manipulation: A review and prospects,” *Sensors*, vol.25, no.17, 2025.

[3] Kadi, H. A. and Terzic, K., “Data-driven robotic manipulation of cloth-like deformable objects: The present, challenges and future prospects,” *Sensors*, vol.23, no.5, article 2389, 2023.

[4] Chi, C., Sun, X., Xue, N., Li, T. and Liu, C., “Recent progress in technologies for tactile sensors,” *Sensors*, vol.18, no.4, article 948, 2018.

[5] Armand, M., Endres, F., MacFarlane, D. R., Ohno, H. and Scrosati, B., “Ionic-liquid materials for the electrochemical challenges of the future,” *Nature Materials*, vol.8, no.8, pp.621–629, 2009.

[6] Chossat, J.-B., Park, Y.-L., Wood, R. J. and Duchaine, V., “A soft strain sensor based on ionic and metal liquids,” *IEEE Sensors Journal*, vol.13, no.9, pp.3405–3414, 2013.

[7] Cadene, R. and et al., “LeRobot: state-of-the-art machine learning for real-world robotics in PyTorch,” GitHub repository, 2024.